

用户查询

```
graph TD; A([用户查询]) --> B[阶段一：查询向量化]; B --> C([向量化查询文本  
(embedding)]); C --> D[阶段二：向量检索]; D --> E([向量相似度搜索  
(vector DB)]); E --> F([检索 Top-K  
相关文档块]); F --> G[阶段三：生成]; G --> H([查询 + 检索结果  
组合输入]); H --> I([注入上下文  
(prompt)]); I --> J([LLM 生成  
最终回答]);
```

阶段一：查询向量化

向量化查询文本
(embedding)

阶段二：向量检索

向量相似度搜索
(vector DB)

检索 Top-K
相关文档块

阶段三：生成

查询 + 检索结果
组合输入

注入上下文
(prompt)

LLM 生成
最终回答